

# Ứng dụng BERT và Contrastive Learning vào bài toán phân tích cảm xúc

Nguyễn Bằng Anh, La Nguyễn Thị Trâm  
Trường Đại học Công Nghệ - Đại học Quốc Gia Hà Nội  
22021101@vnu.edu.vn, 22021125@vnu.edu.vn

Link github: [https://github.com/bangils37/ContrastiveBert\\_Stock\\_Sentiment\\_Analysis](https://github.com/bangils37/ContrastiveBert_Stock_Sentiment_Analysis)

**Abstract**—Trong bài nghiên cứu này, chúng tôi đề xuất ứng dụng mô hình BERT và Contrastive Learning để giải quyết bài toán Stock Sentiment Analysis. Mục tiêu của nghiên cứu là phân tích cảm xúc từ các bình luận về thị trường chứng khoán bằng cách sử dụng mô hình ngôn ngữ BERT. Chúng tôi tinh chỉnh mô hình BERT và cải tiến bằng kỹ thuật Contrastive Learning nhằm nâng cao khả năng học của mô hình với các dữ liệu khó phân biệt.

**Keywords**—stock sentiment analysis, BERT, contrastive learning.

## I. INTRODUCTION

Trong thời đại số hóa hiện nay, sự bùng nổ của mạng xã hội và truyền thông trực tuyến đã mang đến nguồn dữ liệu phong phú về cảm xúc và suy nghĩ của nhà đầu tư và người tiêu dùng. Đặc biệt trong lĩnh vực tài chính, cảm xúc của nhà đầu tư có thể ảnh hưởng đáng kể đến xu hướng thị trường chứng khoán. Phân tích cảm xúc không chỉ giúp dự đoán xu hướng thị trường mà còn cung cấp cái nhìn sâu hơn về tâm lý thị trường.

Tuy nhiên, việc phân tích chính xác cảm xúc từ các bình luận có sử dụng emoji là một thách thức lớn do sự đa dạng về ngữ nghĩa và phong cách sử dụng emoji. Các phương pháp truyền thống cũng như Machine Learning và kỹ thuật dựa trên quy tắc gặp nhiều khó khăn trong việc nhận diện các thông tin phức tạp. Do đó, trong nghiên cứu này, chúng tôi đề xuất ứng dụng mô hình BERT và cải tiến bằng Contrastive Learning với mục tiêu cải thiện độ chính xác và khả năng tổng quát hóa trong bài toán phân tích cảm xúc tài chính.

## II. RELATED WORKS

### A. Phương pháp truyền thống

Các phương pháp truyền thống như mô hình dựa trên quy tắc (rule-based) và học máy (Machine Learning) đã được sử dụng rộng rãi trong phân tích cảm xúc. Rule-based method sử dụng các từ điển cảm xúc và luật để phân loại cảm xúc, tuy nhiên, phương pháp này gặp khó khăn trong việc giải quyết ngữ cảnh và các từ đa nghĩa. Machine learning dựa trên các thuật toán như Naive Bayes và Support Vector Machine (SVM) đã cải thiện độ chính xác nhờ vào việc học từ dữ liệu. Tuy nhiên, các mô hình này phụ thuộc nhiều vào việc lựa chọn đặc trưng và đòi hỏi tập dữ liệu được gán nhãn thủ công, làm giảm tính linh hoạt và hiệu quả.

### B. Phương pháp học sâu

Các mô hình LSTM, CNN đã đạt được kết quả khả quan khi được áp dụng vào bài toán phân tích cảm xúc. Mô hình LSTM có khả năng ghi nhớ thông tin từ các chuỗi dữ liệu dài, giúp nhận diện tốt hơn các mối quan hệ ngữ nghĩa trong văn bản. CNN lại có khả năng tự động trích xuất các đặc trưng quan trọng từ dữ liệu. Tuy nhiên, cả hai phương pháp này vẫn gặp hạn chế trong việc xử lý các văn bản phức tạp và yêu cầu tập dữ liệu lớn để huấn luyện.

### C. Mô hình BERT

Gần đây, các mô hình ngôn ngữ lớn như BERT đã thay đổi cục diện của phân tích cảm xúc nhờ vào khả năng hiểu ngữ cảnh tốt hơn. BERT dựa trên kiến trúc Transformer và có thể học được các mối quan hệ ngữ nghĩa phức tạp trong văn bản. Nhiều nghiên cứu đã chỉ ra rằng BERT cải thiện đáng kể độ chính xác so với các mô hình truyền thống. Tuy nhiên, BERT cũng yêu cầu lượng dữ liệu lớn và thời gian huấn luyện lâu, đồng thời dễ bị ảnh hưởng bởi các mẫu dữ liệu tương tự.

## III. MODEL

### A. Tiền xử lý

Các mô hình học máy, đặc biệt là những mô hình dựa trên kiến trúc Transformer như BERT, không thể làm việc trực tiếp với dữ liệu văn bản thô. Do đó, cần chuyển đổi dữ liệu văn bản thành dạng số học để có thể xử lý.

Đầu tiên, chúng tôi tiến hành tokenizer để chia câu thành các từ, đồng thời gán giá trị số cho từng từ và thêm các token đặc biệt như [CLS] hoặc [SEP].

Sau đó, do BERT yêu cầu các chuỗi đầu vào có chiều dài cố định mà các câu hoặc đoạn văn bản thường có độ dài khác nhau. Chúng tôi sử dụng padding - token [PAD] có giá trị 0, để đảm bảo các chuỗi có độ dài bằng nhau và cố định. Thông qua khảo sát, chúng tôi nhận thấy bộ dữ liệu thường có độ dài ít hơn 120 token nên độ dài tối đa (max\_len) được chọn là 160 token.

BERT sử dụng cơ chế attention để tập trung vào các token quan trọng trong chuỗi đầu vào. Để hỗ trợ quá trình này, một attention mask được tạo ra. Đây là một mảng số với giá trị là 0 và 1 để mô hình xác định các vị trí cần chú ý.

Và cuối cùng, tập dữ liệu được chia ra theo tỉ lệ 80%-10%-10% lần lượt là các tập dữ liệu để training, validation và test.

### B. BERT: Bidirectional Encoder Representations from Transformers

BERT là mô hình ngôn ngữ được đào tạo trước (pre-trained language model), sử dụng lượng lớn dữ liệu để huấn luyện và có thể được điều chỉnh để giải quyết nhiều bài toán khác nhau.

Mô hình BERT lấy ý tưởng phát triển từ transformer - một kiến trúc sequence-to-sequence dựa vào cơ chế attention cho cả encoder và decoder. BERT chỉ sử dụng transformer encoder để đưa tất cả input vào cùng một lúc và quản lý mối quan hệ giữa chúng.


BERT được huấn luyện bằng hai nhiệm vụ chính: Masked Language Model (MLM) và Next Sentence Prediction (NSP). MLM thay ngẫu nhiên từ trong câu bằng token [MASK] và mô hình sẽ dự đoán từ bị che từ cả hai phía, từ đó mô hình có thể hiểu được ngữ cảnh từ cả hai phía. NSP yêu cầu mô hình dự đoán câu thứ hai có phải câu kế tiếp của câu đầu tiên hay không, từ đó giúp mô hình hiểu được mối quan hệ giữa các câu trong đoạn văn.

### C. Fine-tuning

Mô hình chính là một bộ phân loại cảm xúc (Sentiment Classifier) được xây dựng dựa trên kiến trúc BERT-based. Mô hình bao gồm các thành phần:

- BERT Encoder: Được sử dụng để mã hóa ngữ cảnh của văn bản đầu vào, trích xuất biểu diễn ẩn có độ chiều cao từ các token.
- Tầng đầu ra (Output Layer):
  - + Tầng fully-connected với kích thước trung gian là 512, được kích hoạt bằng hàm ReLU.
  - + Dropout với tỷ lệ 50% để giảm thiểu hiện tượng overfitting.
  - + Tầng đầu ra cuối cùng sử dụng softmax để phân loại cảm xúc thành các lớp tương ứng.

### D. Contrastive Learning



Mô hình được cải thiện nhờ áp dụng kỹ thuật Supervised SimCSE. Kỹ thuật này học biểu diễn ngữ nghĩa bằng cách tối đa hóa độ tương đồng giữa các câu có nhãn giống nhau và giảm thiểu độ tương đồng giữa các câu khác nhãn. Công thức tính loss là:

$$-\log \frac{e^{\text{sim}(h_i, h_{i+})/\tau}}{\sum_{j=1}^N (e^{\text{sim}(h_i, h_{j+})/\tau} + e^{\text{sim}(h_i, h_{j-})/\tau})}$$

$h_i$ : Là embedding của câu thứ  $i$ .

$h_{i+}$ : Là embedding của câu tích cực (positive example) tương ứng với câu  $i$ , tức là câu có cùng nhãn với câu  $h_i$ .

$h_{j+}$ : Là embedding của một câu tích cực khác (có nhãn giống

với  $h_i$ ).

$h_{j-}$ : Là embedding của một câu tiêu cực (negative example) khác (có nhãn khác với  $h_i$ ).

(có nhãn khác với

$h_i$ ).  $\text{sim}(h_i, h_j)$ : Là độ tương đồng cosine giữa hai embeddings

$\text{sim}(h_i, h_j)$ : Là độ tương đồng cosine giữa hai embeddings

$h_i$  và  $h_j$ .

$h_i$  và  $h_j$ .

$\tau$ : Là tham số nhiệt độ (temperature), điều chỉnh độ sắc nét của hàm softmax

$N$ : Là số lượng câu trong batch.

Công thức này tính toán hàm mất mát trong học có giám sát cho **SimCSE** (Supervised Contrastive Sentence Embedding). Từ số của công thức là độ tương đồng giữa một câu  $h_i$  và câu tích cực  $h_{i+}$ , được tính và chuẩn hóa với tham số nhiệt độ  $\tau$ . Mẫu số là tổng của độ tương đồng giữa câu  $h_i$  và các câu tích cực khác  $h_{j+}$  cùng với các câu tiêu cực  $h_{j-}$ , cũng được chuẩn hóa với nhiệt độ  $\tau$ . Mục đích của công thức là làm tăng khả năng mô hình nhận diện các câu tích cực tương tự nhau, đồng thời phân biệt chúng với các câu tiêu cực. Cuối cùng, hàm log được áp dụng lên biểu thức này để tính toán mất mát, điều chỉnh các giá trị về xác suất, từ đó tối ưu hóa việc học các embeddings câu sao cho chúng thể hiện đúng mối quan hệ giữa các câu cùng nhãn và khác nhãn.

Trong quá trình huấn luyện, hàm mất mát cuối cùng được kết hợp từ:

- Loss phân loại (CrossEntropyLoss): Để huấn luyện cho bài toán phân loại cảm xúc.

- Loss tương phản (Supervised SimCSE Loss): Để cải thiện biểu diễn ngữ nghĩa của các câu.

Hàm mất mát tổng hợp là:

$$\text{Total Loss} = \text{Classification Loss} + \text{Contrastive Loss}$$

## IV. DATA

	total	train	val	test
bearish	4526	3619	465	442
bullish	5474	4381	535	558
ambiguous	870	698	86	86
amusement	817	651	83	83
anger	386	309	38	39
belief	907	728	89	90
confusion	609	489	60	60
depression	204	166	19	19
disgust	1278	1036	121	121
optimism	1624	1299	163	162
panic	302	240	31	31
surprise	260	196	32	32
total	10000	8000	1000	1000

Tập dữ liệu chúng tôi lựa chọn đó là StockEmotions. StockEmotions là một tập dữ liệu gồm 10.000 câu thu thập từ StockTwits, được thiết kế để phân loại cảm xúc trong lĩnh vực tài chính. Tập dữ liệu chứa 2 lớp cảm xúc tài chính (bullish và

Model (F1 Score)	Sentiment			Emotion												
	bear.	bull.	avg.	ambg.	amus.	angr.	anxt.	belf.	cnfs.	dprs.	disg.	optm.	exct.	panc.	surp.	avg.
LogitReg.	0.71	0.77	0.74	0.12	0.29	0.44	0.37	0.29	0.48	0.24	0.29	0.31	0.39	0.24	0.15	0.32
NBSVM.	0.71	0.78	0.75	0.10	0.27	0.45	0.30	0.36	0.46	0.21	0.34	0.29	0.42	0.29	0.22	0.33
GRU.	0.72	0.79	0.76	0.20	0.31	0.21	0.41	0.15	0.46	0.19	0.33	0.38	0.39	0.43	0.06	0.34
Bi-GRU	0.73	0.78	0.76	0.22	0.33	0.49	0.39	0.30	0.54	0.29	0.39	0.43	0.32	0.41	0.06	0.36
DistilBERT.	0.79	0.83	0.81	0.12	0.37	0.56	0.42	0.42	0.51	0.29	0.43	0.42	0.51	0.48	0.21	0.42
BERT.	0.79	0.83	0.81	0.27	0.30	0.59	0.46	0.37	0.50	0.22	0.37	0.40	0.48	0.41	0.41	0.40
RoBERTa.	0.78	0.82	0.80	0.09	0.25	0.13	0.44	0.29	0.50	0.21	0.43	0.39	0.39	0.11	0.21	0.39
Ours	0.77	0.81	0.79	0.08	0.34	0.19	0.49	0.25	0.59	0.17	0.41	0.44	0.46	0.06	0.00	0.29

Figure 1: Bảng kết quả thực nghiệm

bearish) do người dùng chú thích, cùng 12 lớp cảm xúc được gán nhãn bằng mô hình ngôn ngữ tiền huấn luyện (PLM) và chuyên gia tài chính. Hệ thống phân loại cảm xúc của StockEmotions dựa trên các nghiên cứu tâm lý học, nhằm hỗ trợ nghiên cứu trong lĩnh vực tài chính. Tập dữ liệu này vượt trội hơn các tập trước đây nhờ sự đa dạng của cảm xúc, bao gồm cả cảm xúc tích cực và tiêu cực, kèm theo các thông tin bổ sung như chuỗi thời gian và dữ liệu emoji.

Thông tin về tập dữ liệu:

- Thời gian thu thập dữ liệu: Từ tháng 1/2020 đến tháng 12/2020
- Số lượng phát ngôn: 10.000 (80% train, 10% val, 10% test)
- Lớp cảm xúc: 2 [bullish (~positive), bearish (~negative)]
- Lớp cảm xúc chi tiết: 12 [ambiguous, amusement, anger, anxiety, belief, confusion, depression, disgust, excitement, optimism, panic, surprise]

## V. EXPERIMENTS

Trong nhiệm vụ phân loại, dữ liệu được chia ngẫu nhiên thành ba tập: train (80%), val (10%), và test (10%). Để thiết lập các thí nghiệm cơ bản, chúng tôi tiến hành so sánh các phương pháp học máy khác nhau, bao gồm: (1) Hồi quy Logistic, (2) Naïve Bayes SVM (theo Wang và Manning, 2012); các mô hình mạng nơ-ron tiêu chuẩn như (3) GRU (theo Cho và cộng sự, 2014), (4) Bi-GRU; cùng các mô hình ngôn ngữ tiền huấn luyện như (5) DistilBERT (theo Sanh và cộng sự, 2019), (6) BERTbase (theo Devlin và cộng sự, 2019), (7) RoBERTabase (theo Liu và cộng sự, 2019), và (8) mô hình do chúng tôi đề xuất. Hiệu quả của các phương pháp được đánh giá dựa trên thang đo F1-Score.

### A. Set-up

Đối với nhiệm vụ phân loại, chúng tôi thực hiện 5 lần chạy thí nghiệm độc lập với các hạt giống ngẫu nhiên khác nhau và trình bày kết quả hiệu suất trung bình trên tất cả các lần chạy. Tất cả các thí nghiệm đều được chạy trên GPU Nvidia P100 với 16GB bộ nhớ.

### B. Baselines

Đối với các thí nghiệm mô hình cơ sở phân loại, chúng tôi so sánh các phương pháp học máy, mạng nơ-ron tiêu chuẩn và các mô hình ngôn ngữ đã được tiền huấn luyện như sau:

- Hồi quy Logistic: Một thuật toán dựa trên xác suất để dự đoán lớp có xác suất cao nhất.

- Naïve Bayes SVM (Wang và Manning 2012): Một biến thể của Máy vector hỗ trợ (SVM) sử dụng tỷ lệ log-count Naïve Bayes làm giá trị đặc trưng.

- GRU (Cho et al. 2014): Một cơ chế cổng trong mạng nơ-ron hồi tiếp (RNN), cho thấy kết quả thực nghiệm với hiệu suất tốt hơn trên các tập dữ liệu ít xuất hiện.

- Bi-GRU: Một mô hình hai chiều gồm hai GRU, bao gồm cả hướng tiến và hướng lùi.

- DistilBERT (Sanh et al. 2019): Một phiên bản nhẹ của BERT để huấn luyện nhanh hơn.

- BERTbase (Devlin et al. 2019): Một mô hình ngôn ngữ tiền huấn luyện sâu sử dụng các đại diện mã hóa hai chiều từ Transformer.

- RoBERTabase (Liu et al. 2019): Một phương pháp tối ưu hóa mạnh mẽ cho BERT bằng cách loại bỏ mục tiêu tiền huấn luyện câu kế tiếp.

### C. Metrics

Chúng tôi báo cáo hiệu suất trên từng lớp với chỉ số F1 trong các mô hình cơ sở, được hiển thị trong Figure 1.

### D. Hyperparameter Search

Cài đặt siêu tham số của mỗi mô hình được báo cáo trong Figure 2 (Bảng bên dưới). Các kết quả biến thể được thu được dựa trên sự thay đổi của tỷ lệ học (learning rate). Các cài đặt siêu tham số có hiệu suất tốt nhất được hiển thị bằng chữ in đậm.

Model	hyperparamater search	Dropout
Logistic Reg.	lr.[0.1, <b>0.01</b> , 1e-3]; ep.[5, 10, 30].	dropout [0.2, 0.5]
NBSVM	lr.[0.1, <b>0.01</b> , 1e-3]; ep.[2, 5, 10].	
GRU	lr.[0.1, 0.01, <b>1e-3</b> ]; ep.[3, 6, 9, 10].	
Bi-GRU	lr.[0.1, 0.01, <b>1e-3</b> ]; ep.[3, 6, 9, 10].	
DistilBERT	lr.[1e-4, 1e-6, <b>3e-05</b> ]; ep. [3, 5];	
BERT	lr.[1e-4, 1e-6, <b>3e-05</b> ]; ep. [3, 5];	
RoBERTa	lr.[1e-4, <b>1e-6</b> , 3e-05]; ep. [3, 5];	dropout = 0.5
Ours	lr = 2e-5; ep. ep. [3, 5]	

Figure 2: Hyperparameter Configuration Details. (lr = learning rate, ep = epochs)

## VI. RESULTS

Mô hình của chúng tôi đạt được kết quả khá ấn tượng. Đối với nhiệm vụ phân loại cảm xúc (Sentiment), mô hình của

chúng tôi đạt độ chính xác trung bình 0.79, vượt qua các mô hình truyền thống như LogitReg. (0.74) và NBSVM. (0.75). Mặc dù các mô hình như DistilBERT (0.81) và BERT (0.81) vẫn thể hiện sự vượt trội, mô hình của chúng tôi vẫn duy trì hiệu suất mạnh mẽ.

Trong nhiệm vụ phân loại cảm xúc (Emotion), mô hình của chúng tôi đạt được điểm số khá cao cho các cảm xúc như "anxiety" (0.49) và "belief" (0.59). Các cảm xúc như "surprise" vẫn gặp khó khăn (0.00), có thể do sự thiếu dữ liệu hoặc sự khó khăn trong việc phân biệt cảm xúc này. Tuy nhiên, điểm mạnh của mô hình nằm ở khả năng học sâu các đặc trưng cảm xúc nhờ vào Contrastive Learning, giúp tăng cường khả năng phân loại các cảm xúc có sự tương đồng.

## VII. ANALYSIS AND DISCUSSION

### A. Điểm mạnh

Mô hình có một số ưu điểm rõ rệt:

- Khả năng phân biệt cảm xúc: Mô hình đã thể hiện khả năng phân biệt chính xác giữa các cảm xúc như "anxiety" và "belief", cho thấy hiệu quả của Contrastive Learning trong việc học các đặc trưng phân biệt mạnh mẽ.

- Phân loại tốt cảm xúc tích cực và tiêu cực: Mô hình phân loại cảm xúc tích cực và tiêu cực chính xác hơn so với các mô hình học máy truyền thống, cải thiện hiệu suất đáng kể trong các tác vụ phân loại cảm xúc tổng quát.

### B. Hạn chế

Mặc dù mô hình đã đạt được hiệu suất khá tốt, vẫn có một số vấn đề cần được cải thiện:

- Khó khăn trong phân loại cảm xúc ít xuất hiện: Mô hình gặp khó khăn trong việc phân loại cảm xúc "surprise" (0.00) và "anger" (0.19). Điều này có thể liên quan đến sự không cân bằng trong tập dữ liệu hoặc sự phức tạp của các cảm xúc này.
- Khả năng phân loại các cảm xúc phức tạp: Một số cảm xúc như "confusion" và "optimism" vẫn có điểm số thấp hơn so với các lớp khác, điều này có thể do sự tương đồng giữa các cảm xúc này hoặc sự thiếu đa dạng trong cách các cảm xúc này được thể hiện trong dữ liệu huấn luyện.

## VIII. CONCLUSION

Trong nghiên cứu này, chúng tôi đã áp dụng mô hình BERT, kết hợp với kỹ thuật Contrastive Learning, để phân tích cảm xúc trong các bình luận liên quan đến thị trường chứng khoán. Mục tiêu chính là xây dựng một mô hình phân loại tự động,

không chỉ nhận diện chính xác cảm xúc tích cực và tiêu cực, mà còn phân biệt được các trạng thái cảm xúc phức tạp, từ đó hỗ trợ việc phân tích tâm lý thị trường và dự đoán xu hướng tài chính.

Nhìn chung, mô hình BERT cải tiến đã chứng minh tính hiệu quả trong bài toán phân tích cảm xúc tài chính. Mặc dù vẫn cần cải thiện ở một số nhóm cảm xúc khó, kết quả đạt được là đáng ghi nhận và có thể cải thiện thêm trong tương lai.

## REFERENCES

- [1] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". Proceedings of NAACL-HLT 2019.
- [2] Gao, T., Yao, X., & Chen, D. (2021). "SimCSE: Simple Contrastive Learning of Sentence Embeddings". Proceedings of EMNLP 2021.
- [3] Cai, R., Qin, B., Chen, Y., Zhang, L., Yang, R., Chen, S., & Wang, W. (2020). "Sentiment Analysis About Investors and Consumers in Energy Market Based on BERT-BiLSTM".
- [4] Mittal, A., & Goel, A. "Stock Prediction Using Twitter Sentiment Analysis". Stanford University.
- [5] Khedr, A. E., Salama, S. E., & Yaseen, N. "Predicting Stock Market Behavior using Data Mining Technique and News Sentiment Analysis". Faculty of Computers and Information Technology, Future University in Egypt, Cairo, Egypt.
- [6] Sousa, M. G., Sakiyama, K., Rodrigues, L. S. "BERT for Stock Market Sentiment Analysis". FACOM/UFMS, Campo Grande, Brazil.
- [7] Bharathi, S., & Geetha, A. "Sentiment Analysis for Effective Stock Market Prediction".
- [8] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. "Attention Is All You Need".
- [9] Yan, Y., Li, R., Wang, S., Zhang, F., Wu, W., & Xu, W. "ConSERT: A Contrastive Framework for Self-Supervised Sentence Representation Transfer".
- [10] Jiang, T., Jiao, J., Huang, S., Zhang, Z., Wang, D., Zhuang, F., Wei, F., Huang, H., Deng, D., & Zhang, Q. "PromptBERT: Improving BERT Sentence Embeddings with Prompts".
- [11] Hu, D., Bao, Y., Wei, L., Zhou, W., & Hu, S. "Supervised Adversarial Contrastive Learning for Emotion Recognition in Conversations".
- [12] Hu, D., Wei, L., Liu, Y., Zhou, W., & Hu, S. "UCAS-IIE-NLP at SemEval-2023 Task 12: Enhancing Generalization of Multilingual BERT for Low-resource Sentiment Analysis".
- [13] Su, Y., Liu, F., Meng, Z., & Lan, T. "TaCL: Improving BERT Pre-training with Token-aware Contrastive Learning".
- [14] Kim, T., Yoo, K. M., & Lee, S. "Self-Guided Contrastive Learning for BERT Sentence Representations".
- [15] Banino, A., Badia, A. P., & Walker, J. "COBERL: CONTRASTIVE BERT FOR REINFORCEMENT LEARNING".